

TECH CHALLENGE

FASE 2

FIAP

Grupo:

- | | |
|-------------------------------------|----------|
| • Armando Caliarí Silva | rm372117 |
| • Caike Herbe Jauch Soares | rm371123 |
| • Gabriel Santos de Oliveira Arruda | rm371178 |
| • Gustavo Ferreira da Silva Santana | rm370545 |
| • Kauan Lucas Gomes Jardim | rm370438 |

Data: 14/07/2026

Sumário

1. COMPREENSÃO DO PROBLEMA.....	3
1.1 Definição da variável alvo.....	3
2. ANÁLISE EXPLORATÓRIA DE DADOS (EDA).....	4
2.1 Distribuição da variável quality.....	4
2.2 Balanceamento das classes.....	5
2.4 Detecção de outliers.....	6
2.5 Teor alcoólico por classe de qualidade.....	8
2.6 Matriz de correlação.....	9
3. PRÉ-PROCESSAMENTO DE DADOS.....	11
3.1 Tratamento dos dados faltantes.....	11
3.2 Criação de novas variáveis.....	11
3.3 Separação treino/teste.....	12
3.4 Padronização (Standard Scaler).....	12
3.5 Tratamento do desbalanceamento de classes.....	13
4. DESENVOLVIMENTO DE MODELOS.....	13
5. AVALIAÇÃO DOS MODELOS.....	14
5.1 Comparativo de métricas entre os 7 modelos avaliados.....	14
5.2 Matrizes de confusão.....	16
5.3 Curvas ROC.....	17
5.4 Validação cruzada.....	18
5.5 Comparação final entre os modelos.....	18
6. INTERPRETAÇÃO DOS RESULTADOS.....	18
6.1 Importância das variáveis.....	18
6.2 Implicações para o processo de produção.....	20
7. TESTE DO MODELO EM CASOS PRÁTICOS.....	20
7.1 Função reutilizável de predição.....	20
7.2 Teste com amostras reais do conjunto de teste.....	21
7.3 Teste com vinhos hipotéticos.....	21
8. CONCLUSÃO.....	22
9. REFERÊNCIAS BIBLIOGRÁFICAS.....	22
10. LINKS DE ACESSO.....	23

1. COMPREENSÃO DO PROBLEMA

O objetivo deste projeto é treinar e avaliar modelos de aprendizado de máquina capazes de prever a qualidade de vinhos a partir de características físico-químicas medidas em laboratório.

A base utilizada foi o arquivo WineQT.csv, que contém 1.143 registros de vinhos tintos da variedade portuguesa Vinho Verde. Cada registro traz informações sobre a composição química do vinho, além de uma nota de qualidade atribuída por avaliadores.

As variáveis disponíveis na base são:

- Acidez fixa (fixed acidity)
- Acidez volátil (volatile acidity)
- Ácido cítrico (citric acid)
- Açúcar residual (residual sugar)
- Cloretos (chlorides)
- Dióxido de enxofre livre (free sulfur dioxide)
- Dióxido de enxofre total (total sulfur dioxide)
- Densidade (density)
- pH
- Sulfatos (sulphates)
- Teor alcoólico (alcohol)
- Qualidade do vinho (quality) - variável original, nota de 3 a 8
-

A variável quality representa a nota original do vinho, variando de 3 a 8. Como o desafio propõe um problema de classificação binária, essa nota foi transformada em uma nova variável alvo.

1.1 Definição da variável alvo

Para simplificar a análise e permitir o treinamento dos modelos de classificação, a variável quality foi convertida em duas classes:

- target = 1, quando o vinho possui nota maior ou igual a 7, sendo classificado como "bom"
- target = 0, quando o vinho possui nota menor que 7, sendo classificado como "comum"

Dessa forma, o problema deixa de ser a previsão exata da nota do vinho e passa a ser a identificação de quais amostras têm maior chance de serem classificadas como vinhos de boa qualidade.

Essa transformação é importante porque aproxima o problema de uma situação prática. Em vez de tentar prever cada nota individualmente, o modelo busca apoiar a tomada de decisão ao indicar se um vinho possui ou não perfil de alta qualidade com base em suas características químicas.

2. ANÁLISE EXPLORATÓRIA DE DADOS (EDA)

A análise exploratória teve como objetivo entender melhor a estrutura da base, identificar padrões iniciais e verificar possíveis pontos de atenção antes da etapa de modelagem. Nessa fase, foram analisadas a distribuição da variável de qualidade, o balanceamento das classes, a presença de dados faltantes ou duplicados, possíveis outliers e as principais relações entre as variáveis físico-químicas do vinho.

2.1 Distribuição da variável quality




Figura 1 - Distribuição original das notas de qualidade

A variável quality representa a nota original atribuída aos vinhos. Observa-se que a maior parte das amostras está concentrada nas notas 5 e 6, que representam vinhos de qualidade intermediária. Já as notas extremas aparecem com baixa frequência, sendo apenas 6 vinhos com nota 3 e 16 vinhos com nota 8.

Essa concentração nas notas centrais indica que a base possui poucos exemplos de vinhos nas faixas mais baixas e mais altas de qualidade. Esse comportamento é importante porque influencia diretamente a criação da variável binária e pode afetar o desempenho dos modelos, principalmente na identificação dos vinhos classificados como bons.

Por esse motivo, foi necessário analisar o balanceamento das classes após a transformação da variável quality em target.

2.2 Balanceamento das classes




Figura 2 - Balanceamento da classe target.

Após a transformação da variável quality em uma classificação binária, foi possível observar um forte desbalanceamento entre as classes. A classe "bom", representada por target = 1, corresponde a apenas 13,9% da base, com 159 amostras. Já a classe "comum", representada por target = 0, concentra 86,1% da base, com 984 observações.

Esse ponto é relevante porque um modelo poderia atingir uma acurácia aparentemente alta apenas prevendo sempre a classe majoritária. Por exemplo, se o modelo classifica se todos os vinhos como "comuns", ele já teria aproximadamente 86% de acurácia, mas não estaria aprendendo a identificar corretamente os vinhos de boa qualidade.

Por isso, a acurácia sozinha não é suficiente para avaliar os modelos neste projeto. Também foi necessário utilizar métricas como precision, recall, F1-Score e ROC-AUC, além de aplicar técnicas para reduzir o impacto do desbalanceamento na etapa de pré-processamento.

2.3 Dados faltantes e duplicados


Verificação	Resultado
Valores nulos (total)	0
Linhas duplicadas	0

Tabela 1 - Dados faltantes e duplicados

Durante a verificação inicial da base, não foram encontrados valores nulos nas colunas analisadas. Também não foram identificadas linhas duplicadas no dataset.

Com isso, não foi necessário realizar preenchimento de dados faltantes nem remover registros duplicados. Essa condição favorece a etapa de modelagem, pois reduz a necessidade de tratamentos adicionais antes da preparação dos dados.

2.4 Detecção de outliers






Figura 3 - Boxplots de todas as variáveis numéricas.

Uma vez que identificamos algumas variáveis com outliers, os avaliamos utilizando o método IQR ($1,5 \times \text{IQR}$), que é uma medida de variabilidade, também chamada de midspread ou 50% central dos dados, correspondendo à diferença entre o terceiro quartil (Q3, percentil 75) e o primeiro quartil (Q1, percentil 25) e, é usada, principalmente, para medir a dispersão dos 50% centrais dos dados e identificar outliers (Mishra et al., 2019):

Variável	Nº de outliers (identificado via método IQR)	% do dataset
residual sugar	110	9,62%
chlorides	77	6,74%
fixed acidity	44	3,85%
sulphates	43	3,76%
total sulfur dioxide	40	3,50%

Tabela 2 - Top 5 variáveis com maiores outliers

Apesar da presença desses valores, optou-se por não removê-los. Essa decisão foi tomada por três motivos principais.

1. A base possui apenas 1.143 registros, e a classe de vinhos "bons" tem somente 159 amostras. Remover linhas poderia reduzir ainda mais a quantidade de dados disponíveis para o treinamento.
2. Valores físico-químicos fora do padrão podem representar características importantes de vinhos muito bons ou muito ruins. Portanto, esses registros podem carregar informações úteis para o modelo.
3. Alguns modelos utilizados, como o Random Forest, lidam melhor com outliers, pois se baseiam em divisões sucessivas dos dados e não dependem diretamente da distância entre as observações.

2.5 Teor alcoólico por classe de qualidade




Figura 4 - Distribuição do teor alcoólico por classe.

Observa-se que vinhos classificados como "bons" apresentam teor alcoólico visivelmente mais alto e são, portanto, mais concentrados, um padrão que se confirma na análise de correlação que segue, em que podemos observar melhor a importância das variáveis do modelo final.

Ao comparar o teor alcoólico entre as duas classes, observa-se que os vinhos classificados como "bons" tendem a apresentar teor alcoólico mais alto do que os vinhos classificados como "comuns".

Esse resultado indica que o teor alcoólico pode ser uma variável relevante para diferenciar vinhos de melhor qualidade. Na prática, isso sugere que vinhos com maior teor alcoólico podem estar associados a processos de fermentação mais completos ou a uvas com maior maturação, fatores que podem contribuir para uma melhor avaliação sensorial.

2.6 Matriz de correlação




Figura 5 - Matriz de correlação entre todas as variáveis

De forma tabular, temos a correlação de cada variável com o target, ordenada (excluindo a própria quality):

Tabela 3 - Correlação entre variável target e demais variáveis

Variável	Correlação com target
alcohol	+0,40
citric acid	+0,25
sulphates	+0,21
fixed acidity	+0,12
residual sugar	+0,06

free sulfur dioxide	-0,06
pH	-0,07
chlorides	-0,10
total sulfur dioxide	-0,11
density	-0,15
volatile acidity	-0,30

A matriz de correlação foi utilizada para entender como as variáveis se relacionam entre si e com a variável alvo. Essa análise ajuda a identificar quais características físico-químicas têm maior associação com a qualidade do vinho.

As variáveis com maior correlação positiva com o target foram:

- alcohol, com correlação de +0,40
- citric acid, com correlação de +0,25
- sulphates, com correlação de +0,21

Isso indica que vinhos com maior teor alcoólico, maior presença de ácido cítrico e níveis adequados de sulfatos tendem a estar mais associados à classe de vinhos "bons". Por outro lado, algumas variáveis apresentaram correlação negativa com o target, com destaque para:

- volatile acidity, com correlação de -0,30
- density, com correlação de -0,15
- total sulfur dioxide, com correlação de -0,11

A acidez volátil foi a variável com correlação negativa mais forte. Isso faz sentido do ponto de vista químico, pois valores elevados de acidez volátil podem estar associados a defeitos de fermentação e prejudicar a qualidade percebida do vinho.

A densidade também aparece com correlação negativa, o que pode estar relacionado à presença de mais açúcar residual e menor teor alcoólico. Já o dióxido de enxofre total apresenta uma relação negativa mais discreta, podendo indicar que níveis mais elevados de conservação química não estão necessariamente associados a vinhos de melhor qualidade.

Com base nessa análise, foi possível identificar variáveis com maior potencial explicativo para a modelagem. Entre elas, o teor alcoólico se destacou como a variável mais relevante na análise exploratória, sendo posteriormente confirmado na etapa de interpretação dos modelos.

Assim, temos com maior correlação as seguintes variáveis:

- Álcool (+0,40): Vinhos com maior teor alcoólico tendem a ser avaliados como melhores geralmente associado a uvas mais maduras e fermentação mais completa.
- Ácido cítrico (+0,25) e sulfatos (+0,21): ácido cítrico contribui para o frescor e sabor; sulfatos atuam como conservante e antioxidante, e em níveis equilibrados melhoram a percepção de qualidade.
- Acidez volátil (-0,30): correlação negativa mais forte. A acidez volátil em excesso está associada a defeitos de fermentação (gosto de vinagre), prejudicando a qualidade coerente com a química do vinho.
- Densidade (-0,15) e dióxido de enxofre total (-0,11): correlações negativas mais discretas; densidade mais alta tende a se associar a mais açúcar residual e menos álcool, e excesso de SO₂ total pode indicar conservação mais agressiva, associada a vinhos de qualidade inferior.

3. PRÉ-PROCESSAMENTO DE DADOS

3.1 Tratamento dos dados faltantes

Conforme verificado na etapa de análise exploratória, o dataset não apresentou valores nulos nas colunas analisadas. Também não foram encontradas linhas duplicadas.

Mesmo assim, essa verificação foi importante para garantir a qualidade da base antes da modelagem. Como não havia dados ausentes nem registros repetidos, não foi necessário aplicar técnicas de preenchimento de valores ou remoção de duplicados.

3.2 Criação de novas variáveis

Foram criadas 5 novas variáveis combinando conhecimento de domínio sobre química do vinho, buscando capturar relações que as features originais isoladas não capturam:

- acid_ratio = fixed acidity / volatile acidity - relação entre "acidez boa" (estrutura) e "acidez ruim" (defeito).
- total_acidity = soma das três acidez (fixa, volátil, cítrica) - acidez total percebida.
- free_so2_ratio = free sulfur dioxide / total sulfur dioxide - eficácia da conservação.
- alcohol_density_ratio = alcohol / density - captura a relação inversa natural entre essas variáveis.
- sugar_alcohol = residual sugar × alcohol - interação entre doçura e teor alcoólico.

Feito isso, identificamos a correlação das novas delas com o target:

Tabela 4 - Correlação entre variável target e novas variáveis

Feature criada	Correlação com target
alcohol_density_ratio	+0,40
acid_ratio	+0,32
sugar_alcohol	+0,15
free_so2_ratio	+0,12
total_acidity	+0,11

Alcohol_density_ratio (razão de densidade de álcool) e acid_ratio (proporção de ácido) apresentaram correlação com o target tão forte quanto diversas variáveis originais. Essas duas features ficaram, inclusive, entre as 5 mais importantes do modelo final (ver Seção 6), validando a estratégia de feature engineering.

3.3 Separação treino/teste

Depois da preparação inicial, os dados foram separados em conjunto de treino e conjunto de testes. Foi utilizada a divisão de 80% dos dados para treino e 20% para teste. Com isso, 914 amostras foram usadas para treinar os modelos e 229 amostras foram reservadas para avaliar o desempenho final.

A separação foi feita de forma estratificada, usando stratify=y. Essa escolha garante que os conjuntos de treino e teste mantenham proporções semelhantes entre as classes "bom" e "comum".

Esse cuidado foi necessário porque a base é desbalanceada. Como a classe de vinhos "bons" representa uma parcela pequena da base, uma divisão aleatória sem estratificação poderia gerar um conjunto de teste com poucos exemplos dessa classe, prejudicando a avaliação dos modelos (Silva, Bianchini e Dias, 2021).

3.4 Padronização (Standard Scaler)

As variáveis numéricas da base possuem escalas diferentes. Por exemplo, a variável total sulfur dioxide pode chegar a valores na casa das centenas, enquanto a variável density fica próxima de 1. Essa diferença de escala pode prejudicar alguns modelos, principalmente aqueles baseados em distância, como o KNN. Nesse tipo de modelo, variáveis com valores maiores podem ter peso excessivo no cálculo, mesmo que não sejam necessariamente mais importantes.

Para evitar esse problema, foi aplicada a padronização das variáveis com o StandardScaler. Esse processo transforma os dados para que tenham média igual a 0 e desvio padrão igual a 1.

Um cuidado importante foi ajustar o StandardScaler apenas com os dados de treino e depois aplicar a transformação nos dados de treino e teste. Isso evita vazamento de dados, que acontece quando informações do conjunto de teste são usadas indiretamente durante o treinamento. Caso isso ocorresse, as métricas poderiam parecer melhores do que realmente são.

3.5 Tratamento do desbalanceamento de classes

O desbalanceamento das classes foi um dos principais pontos de atenção do projeto. Como a maior parte dos vinhos foi classificada como "comum", havia o risco de os modelos aprenderem a prever quase sempre essa classe, sem identificar corretamente os vinhos "bons".

Para lidar com esse problema, foram testadas duas abordagens, a primeira foi o uso do SMOTE, técnica que cria novas amostras sintéticas da classe minoritária. No caso deste projeto, ele foi usado para aumentar a representatividade dos vinhos classificados como "bons" no conjunto de treino.

A segunda abordagem foi o uso do parâmetro `class_weight='balanced'`, que ajusta o peso das classes durante o treinamento. Com isso, erros na classe minoritária passam a ter maior impacto para o modelo, ajudando a reduzir o viés em favor da classe majoritária.

Um ponto importante é que o SMOTE foi aplicado apenas no conjunto de treino, depois da separação entre treino e teste. Essa escolha evita que dados sintéticos apareçam no conjunto de teste, o que poderia distorcer a avaliação dos modelos.

Com essas etapas, a base ficou preparada para o treinamento dos modelos de classificação, mantendo a coerência estatística e reduzindo riscos de avaliações artificiais.

Resultado do balanceamento via SMOTE no treino:

Conjunto	Classe 0 (comum)	Classe 1 (bom)
Treino original	787	127
Treino após SMOTE	787	787

Tabela 5 - Resultados pré e pós-SMOTE

4. DESENVOLVIMENTO DE MODELOS

Após o pré-processamento, foram treinados cinco modelos de classificação para prever se um vinho seria classificado como "bom" ou "comum". Entre eles:

- KNN
- Naive Bayes Gaussiano
- Regressão Logística
- Random Forest

- Random Forest com `class_weight='balanced'`

A escolha desses modelos permitiu comparar abordagens diferentes. O KNN foi utilizado por trabalhar com proximidade entre amostras. O Naive Bayes foi usado como modelo simples de referência. A Regressão Logística foi incluída por ser um modelo interpretável para classificação binária. Já o Random Forest foi testado por lidar melhor com relações não lineares e ser mais robusto a outliers.

Também foi avaliada uma versão do Random Forest com ajuste de peso das classes, para reduzir o impacto do desbalanceamento entre vinhos "comuns" e "bons".

Além disso, alguns modelos foram treinados com dados balanceados via SMOTE, enquanto outros foram mantidos sem esse tratamento. Essa comparação permitiu avaliar se o balanceamento melhorou a identificação dos vinhos de maior qualidade.

5. AVALIAÇÃO DOS MODELOS

A avaliação dos modelos foi feita considerando métricas adequadas para um problema com classes desbalanceadas. Como apenas 13,9% dos vinhos foram classificados como "bons", a acurácia não poderia ser usada sozinha, pois um modelo que previsse quase todos os vinhos como "comuns" já teria um resultado aparentemente alto.

Por isso, além da acurácia, foram analisadas métricas como precisão, recall, F1-Score e ROC-AUC. O F1-Score foi usado como principal métrica de comparação, pois equilibra precisão e recall, ajudando a avaliar melhor a capacidade do modelo de identificar a classe minoritária.

5.1 Comparativo de métricas entre os 7 modelos avaliados

Modelo	Acurácia	Precisão	Recall	F1-Score	ROC-AUC
Random Forest (class_weight)	0,908	0,720	0,563	0,632	0,910
Random Forest + SMOTE	0,878	0,553	0,656	0,600	0,910
Random Forest (baseline)	0,895	0,654	0,531	0,586	0,924
KNN + SMOTE	0,799	0,383	0,719	0,500	0,819
KNN (baseline)	0,886	0,650	0,406	0,500	0,816
Logistic Regression + SMOTE	0,799	0,375	0,656	0,477	0,864
Native Bayes +SMOTE	0,782	0,350	0,656	0,457	0,811




Figura 6 - Comparativo visual de métricas entre modelos.

Foram comparados sete modelos ou variações de modelos. O objetivo foi verificar qual abordagem apresentava melhor desempenho para classificar vinhos como "bons" ou "comuns".

De forma geral, os modelos baseados em Random Forest apresentaram os melhores resultados. O Random Forest com `class_weight='balanced'` teve o melhor desempenho geral, com F1-Score de 0,632 e ROC-AUC de 0,910, utilizando os dados originais e sem criar amostras sintéticas.

O Random Forest com SMOTE também apresentou bom desempenho, com F1-Score de 0,600 e recall mais alto. Isso indica que ele conseguiu identificar mais vinhos bons, embora com maior risco de classificar alguns vinhos comuns como bons.

5.2 Matrizes de confusão




Figura 7 - Matrizes de confusão dos 4 principais modelos.

As matrizes de confusão foram usadas para visualizar os acertos e erros dos modelos. Essa análise foi importante porque permitiu observar não apenas quantos registros foram classificados corretamente, mas também onde os erros ocorreram. No contexto do projeto, um ponto de atenção era reduzir os falsos negativos, ou seja, evitar que vinhos realmente bons fossem classificados como comuns.

Os modelos com tratamento de desbalanceamento apresentaram melhor capacidade de identificar a classe "bom" em comparação aos modelos sem tratamento.

5.3 Curvas ROC




Figura 8 - Curvas ROC comparando todos os modelos.

As curvas ROC foram utilizadas para comparar a capacidade dos modelos de separar as duas classes. O ROC-AUC complementou a análise das demais métricas, pois mostra o desempenho do modelo considerando diferentes pontos de corte. Nesse indicador, o Random Forest com `class_weight='balanced'` também se destacou, reforçando sua escolha como modelo final.

5.4 Validação cruzada

Modelo	F1 Médio (CV)	Desvio Padrão
Random Forest	0,937	~ 0,012
Naive Bayes	0,823	~ 0,010

Para testar o modelo, foi aplicada validação cruzada estratificada com 5 divisões. Essa etapa foi importante porque a base possui poucos registros, então o resultado poderia variar dependendo da separação entre treino e teste.

O modelo Random Forest treinado com dados balanceados via SMOTE apresentou F1-Score médio de 0,937, com baixa variação entre as divisões. Esse resultado indica consistência durante a validação cruzada.

5.5 Comparação final entre os modelos

Ao comparar os resultados, o Random Forest com `class_weight='balanced'` foi escolhido como o modelo final. Ele apresentou o melhor equilíbrio entre F1-Score e ROC-AUC, sem depender da criação de dados sintéticos.

O Random Forest com SMOTE ficou próximo e pode ser uma alternativa caso o objetivo principal seja encontrar o maior número possível de vinhos bons. Porém, para uma escolha mais equilibrada e robusta, o modelo com `class_weight='balanced'` foi considerado mais adequado.

Os modelos KNN e Naive Bayes tiveram desempenho inferior, principalmente pela dificuldade em lidar com a sobreposição entre as classes e com o desbalanceamento da base.

6. INTERPRETAÇÃO DOS RESULTADOS

6.1 Importância das variáveis

A análise de importância das variáveis foi feita com base no modelo Random Forest. O objetivo foi entender quais características mais contribuíram para a classificação dos vinhos como "bons" ou "comuns".




Figura 9 - Importância das variáveis no Random Forest.

Posição	Variável	Importância
1º	alcohol	0,149
2º	alcohol_density_ratio (criada)	0,141
3º	sulphates	0,117
4º	acid_ratio (criada)	0,112
5º	citric acid	0,081

O teor alcoólico foi a variável original mais importante, confirmando o padrão observado na análise exploratória. Vinhos com maior teor alcoólico tendem a aparecer mais associados à classe "bom".

A variável `alcohol_density_ratio`, criada na etapa de feature engineering, também teve alta importância. Isso mostra que a relação entre álcool e densidade ajudou o modelo a diferenciar melhor os vinhos.

Outra variável relevante foi `acid_ratio`, que relaciona acidez fixa e acidez volátil. Esse resultado indica que a proporção entre diferentes tipos de acidez pode ser mais informativa do que olhar cada variável separadamente.

A acidez volátil também teve papel importante, mas com efeito negativo. Valores mais altos dessa variável tendem a estar associados a vinhos de menor qualidade.

6.2 Implicações para o processo de produção

Os resultados indicam alguns pontos que podem ser acompanhados com mais atenção no processo produtivo.

O primeiro é o controle do teor alcoólico, já que ele apareceu como uma das variáveis mais ligadas à qualidade do vinho. Isso pode estar relacionado à maturação das uvas e ao processo de fermentação. Outro ponto importante é o monitoramento da acidez volátil. Quando essa acidez está alta, pode indicar problemas no processo, como falhas de fermentação ou oxidação, prejudicando a qualidade final. Os sulfatos também se mostraram relevantes. Em níveis adequados, eles podem contribuir para a conservação do vinho, mas precisam ser controlados para não afetar negativamente o produto.

Por fim, é importante destacar que os resultados valem para o contexto da base utilizada, formada por vinhos tintos portugueses do tipo Vinho Verde. Antes de aplicar essas conclusões em outros tipos de vinho, seria necessário testar o modelo com novas bases de dados.

7. TESTE DO MODELO EM CASOS PRÁTICOS

Para fechar o ciclo do pipeline, o modelo final escolhido foi o Random Forest com `class_weight='balanced'`, pois apresentou o melhor equilíbrio entre F1-Score e ROC-AUC na etapa de avaliação. Esse modelo foi usado para gerar previsões em casos concretos, incluindo amostras reais do conjunto de teste e vinhos hipotéticos com valores definidos manualmente.

O objetivo dessa etapa foi verificar se o modelo, além de apresentar boas métricas, também gera resultados coerentes quando aplicado a exemplos práticos.

7.1 Função reutilizável de predição

Foi criada uma função chamada `predict_wine_quality()`, que recebe as 11 variáveis físico-químicas originais de um vinho e retorna a classificação prevista pelo modelo.

A função aplica os mesmos tratamentos usados no treino, incluindo a criação das novas variáveis e a padronização dos dados. Com isso, o pipeline pode ser reutilizado para classificar novos vinhos de forma padronizada.

7.2 Teste com amostras reais do conjunto de teste

Foram seleccionadas 5 amostras reais do conjunto de teste (não vistas durante o treino), incluindo exemplos de ambas as classes, para comparar a predição do modelo com o valor real conhecido:

Amostra (Índice)	Real	Predito	Prob. “Bom”	Resultado
162	Bom	Comum	21,4%	Errou
822	Bom	Bom	74,5%	Acertou
636	Comum	Bom	61,7%	Errou
1004	Comum	Comum	36,7%	Acertou
640	Comum	Comum	16,7%	Acertou

O modelo acertou 3 das 5 amostras, o que representa 60% de acerto nesse teste pontual. Esse resultado está coerente com as métricas observadas na avaliação geral, principalmente considerando que vinhos próximos da nota de corte podem ser mais difíceis de classificar.

Os erros ocorreram em casos próximos do limite entre as classes, o que é esperado, já que a diferença entre um vinho com nota 6 e outro com nota 7 pode ser pequena em termos físico-químicos.

7.3 Teste com vinhos hipotéticos

Foram simulados dois vinhos hipotéticos com valores físico-químicos definidos manualmente, alinhados às variáveis mais importantes do modelo: um com perfil associado a alta qualidade (teor alcoólico alto, acidez volátil baixa, sulfatos adequados) e outro com perfil associado a qualidade inferior (teor alcoólico baixo, acidez volátil alta).

Variável	Vinho Hipotético “Bom”	Vinho Hipotético “Comum”
alcohol	12,5	9,4
volatile acidity	0,32	0,85
sulphates	0,85	0,55
total sulfur dioxide	40,0	90,0
Predição do modelo	Bom (81,7 confiança)	Comum (100% confiança)

O primeiro tinha características mais associadas a vinhos de boa qualidade, como teor alcoólico mais alto, acidez volátil mais baixa e sulfatos em nível adequado. Esse vinho foi classificado como "bom" pelo modelo. O segundo exemplo tinha perfil mais associado a vinhos comuns, com teor alcoólico mais baixo e acidez volátil mais alta. Nesse caso, o modelo classificou o vinho como "comum".

Esses testes mostram que o modelo apresentou respostas coerentes com os padrões identificados na análise exploratória e na interpretação das variáveis.

8. CONCLUSÃO

O projeto foi desenvolvido seguindo as etapas solicitadas no desafio: compreensão do problema, análise exploratória, pré-processamento, desenvolvimento dos modelos, avaliação e interpretação dos resultados.

Um dos principais pontos tratados foi o desbalanceamento das classes, já que 86,1% dos vinhos foram classificados como "comuns" e apenas 13,9% como "bons". Para lidar com isso, foram testadas técnicas como SMOTE e `class_weight='balanced'`, além do uso de métricas mais adequadas do que apenas a acurácia, como F1-Score, recall e ROC-AUC.

Também foi utilizada separação estratificada entre treino e teste, garantindo que a proporção das classes fosse mantida nos dois conjuntos. Além disso, foram criadas cinco novas variáveis a partir de relações químicas do vinho, sendo que duas delas ficaram entre as mais importantes no modelo final.

Ao todo, foram treinados e comparados cinco modelos: KNN, Naive Bayes, Random Forest, Regressão Logística e Random Forest com `class_weight='balanced'`. Essa comparação permitiu escolher a abordagem com melhor desempenho.

A validação cruzada foi usada para reforçar a consistência dos resultados, considerando que a base possui poucos registros. Por fim, a interpretação das variáveis mais importantes mostrou que fatores como teor alcoólico, densidade, sulfatos e acidez estão diretamente ligados à classificação da qualidade do vinho.

Assim, o projeto mostrou que modelos de aprendizado de máquina podem apoiar a análise da qualidade dos vinhos, desde que os resultados sejam interpretados com cuidado e considerando as limitações da base utilizada.

9. REFERÊNCIAS BIBLIOGRÁFICAS

- Boulton, R.B., Singleton, V., Bisson, L., and Kunkkee, R., Principles and Practices of Winemaking. 1996 Chapman & Hall, New York.
- MISHRA, Prabhaker; PANDEY, Chandra M.; SINGH, Uttam; GUPTA, Anshul; SAHU, Chinmoy; KESHRI, Amit. Descriptive statistics and normality tests for statistical data. Annals of Cardiac Anaesthesia, v. 22, n. 1, p. 67–72, 2019. DOI: 10.4103/aca.ACA_157_18.

- MAZZEO, Jacopo. What Does ‘Volatile Acidity’ Mean in Wine? Wineenthusiast, 2021. Disponível em https://www.wineenthusiast.com/basics/drinks-terms-defined/volatile-acidity-wine/?srsltid=AfmBOopQSM0H5DhjQuFXPlzS5olqfmtRvyjRIgHG-xR7PJNorG_iJR3S. Acesso em 21 de junho de 2026 às 22h.
- SILVA, P. L. N.; BIANCHINI, Z. M.; DIAS, A. J. R. Amostragem: teoria e prática usando R. [S. l.]: [s. n.], capítulo 11 - Amostragem estratificada, 2021

10. LINKS DE ACESSO

- GitHub: https://github.com/gabriel07099/TechChallenge_Fase2
- Apresentação: https://www.youtube.com/watch?v=heXW__MCC5g